



Trabalho Prático | DGT2823 Tecnologias para desenv. de soluções de big data

Kaio Rabello Sales - 202401232874

103 Polo West Shopping - Campo Grande - RJ

Tecnologias para desenv. de soluções de big data – 9002 – 2026.1

Objetivo da Prática

- Descrever como ler um arquivo CSV usando a biblioteca Pandas (Python);
- Descrever como criar um subconjunto de dados a partir de um conjunto existente usando a biblioteca Pandas (Python);
- Descrever como configurar o número máximo de linhas a serem exibidas na visualização de um conjunto de dados usando a biblioteca Pandas (Python);
- Descrever como exibir as primeiras e últimas “N” linhas de um conjunto de dados usando a biblioteca Pandas (Python); Descrever como exibir informações gerais sobre as colunas, linhas e dados de um conjunto de dados usando a biblioteca Pandas (Python);

Microatividade 1: Descrever como ler um arquivo CSV usando a biblioteca Pandas (Python)

Códigos Desenvolvidos:

```
import pandas as pd
```

```

dados = pd.read_csv(

    "pico_web.csv",

    sep=";",

    engine="python",

    encoding="utf-8"

)

print(dados)

```

Saida do código:

```

...      ID  Duration      Date  Pulse  Maxpulse  Calories
0      0      60  '2020/12/01'    110     130    4091.0
1      1      60  '2020/12/02'    117     145    4790.0
2      2      60  '2020/12/03'    103     135    3400.0
3      3      45  '2020/12/04'    109     175    2824.0
4      4      45  '2020/12/05'    117     148    4060.0
5      5      60  '2020/12/06'    102     127    3000.0
6      6      60  '2020/12/07'    110     136    3740.0
7      7      450  '2020/12/08'    104     134    2533.0
8      8      30  '2020/12/09'    100     133    1051.0
9      9      60  '2020/12/10'     98     124    2690.0
10     10     60  '2020/12/11'    103     147    3293.0
11     11     60  '2020/12/12'    100     120    2507.0
12     12     60  '2020/12/12'    100     120    2507.0
13     13     60  '2020/12/13'    106     128    3453.0
14     14     60  '2020/12/14'    104     132    3793.0
15     15     60  '2020/12/15'     98     123    2750.0
16     16     60  '2020/12/16'     98     120    2152.0
17     17     60  '2020/12/17'    100     120    3000.0
18     18     45  '2020/12/18'     90     112         NaN
19     19     60  '2020/12/19'    103     123    3230.0
20     20     45  '2020/12/20'     97     125    2430.0
21     21     60  '2020/12/21'    108     131    3642.0
22     22     45         NaN    100     119    2820.0
23     23     60  '2020/12/23'    130     101    3000.0
24     24     45  '2020/12/24'    105     132    2460.0
25     25     60  '2020/12/25'    102     126    3345.0
26     26     60  20201226    100     120    2500.0
27     27     60  '2020/12/27'     92     118    2410.0
28     28     60  '2020/12/28'    103     132         NaN
29     29     60  '2020/12/29'    100     132    2800.0
30     30     60  '2020/12/30'    102     129    3803.0
31     31     60  '2020/12/31'     92     115    2430.0

```

Microatividade 2: Descrever como criar um subconjunto de dados a partir de um conjunto existente usando a biblioteca Pandas (Python)

Códigos Desenvolvidos:

```
subconjunto = dados [['Pulse', 'Maxpulse', 'Calories']]  
  
print(subconjunto)
```

Saida do Código:

```
#Microatividade 2  
subconjunto = dados [['Pulse', 'Maxpulse', 'Calories']]  
print(subconjunto)
```

	Pulse	Maxpulse	Calories
0	110	130	4091.0
1	117	145	4790.0
2	103	135	3400.0
3	109	175	2824.0
4	117	148	4060.0
5	102	127	3000.0
6	110	136	3740.0
7	104	134	2533.0
8	109	133	1951.0
9	98	124	2690.0
10	103	147	3293.0
11	100	120	2507.0
12	100	120	2507.0
13	106	128	3453.0
14	104	132	3793.0
15	98	123	2750.0
16	98	120	2152.0
17	100	120	3000.0
18	90	112	NaN
19	103	123	3230.0
20	97	125	2430.0
21	108	131	3642.0
22	100	119	2820.0
23	130	101	3000.0
24	105	132	2460.0
25	102	126	3345.0
26	100	120	2500.0
27	92	118	2410.0
28	103	132	NaN
29	100	132	2800.0
30	102	129	3803.0
31	92	115	2430.0

Microatividade 3: Descrever como configurar o número máximo de linhas a serem exibidas na visualização de um conjunto de dados usando a biblioteca Pandas (Python)

Códigos desenvolvidos:

```
pd.set_option("display.max_rows", 9999)  
  
print(dados.to_string())
```

Saida do codigo:

```
#Microatividade 3
pd.set_option("display.max_rows", 9999)

print(dados.to_string())
```

	ID	Duration	Date	Pulse	Maxpulse	Calories
0	0	60	'2020/12/01'	110	130	4091.0
1	1	60	'2020/12/02'	117	145	4790.0
2	2	60	'2020/12/03'	103	135	3400.0
3	3	45	'2020/12/04'	109	175	2824.0
4	4	45	'2020/12/05'	117	148	4060.0
5	5	60	'2020/12/06'	102	127	3000.0
6	6	60	'2020/12/07'	110	136	3740.0
7	7	450	'2020/12/08'	104	134	2533.0
8	8	30	'2020/12/09'	109	133	1951.0
9	9	60	'2020/12/10'	98	124	2690.0
10	10	60	'2020/12/11'	103	147	3293.0
11	11	60	'2020/12/12'	100	120	2507.0
12	12	60	'2020/12/12'	100	120	2507.0
13	13	60	'2020/12/13'	106	128	3453.0
14	14	60	'2020/12/14'	104	132	3793.0
15	15	60	'2020/12/15'	98	123	2750.0
16	16	60	'2020/12/16'	98	120	2152.0
17	17	60	'2020/12/17'	100	120	3000.0
18	18	45	'2020/12/18'	90	112	NaN
19	19	60	'2020/12/19'	103	123	3230.0
20	20	45	'2020/12/20'	97	125	2430.0
21	21	60	'2020/12/21'	108	131	3642.0
22	22	45	NaN	100	119	2820.0
23	23	60	'2020/12/23'	130	101	3000.0
24	24	45	'2020/12/24'	105	132	2460.0
25	25	60	'2020/12/25'	102	126	3345.0
26	26	60	20201226	100	120	2500.0
27	27	60	'2020/12/27'	92	118	2410.0
28	28	60	'2020/12/28'	103	132	NaN
29	29	60	'2020/12/29'	100	132	2800.0
30	30	60	'2020/12/30'	102	120	3803.0
31	31	60	'2020/12/31'	92	115	2430.0

Microatividade 4: Descrever como exibir as primeiras e últimas “N” linhas de um conjunto de dados usando a biblioteca Pandas (Python)

Códigos desenvolvidos:

```
print(dados.head(10))

print(dados.tail(10))
```

Saida do codigo:

```
[18]: #Microatividade 4
      print(dados.head(10))

      ID  Duration  Date      Pulse  Maxpulse  Calories
0  0         60  '2020/12/01'    110      130    4091.0
1  1         60  '2020/12/02'    117      145    4790.0
2  2         60  '2020/12/03'    103      135    3400.0
3  3         45  '2020/12/04'    109      175    2824.0
4  4         45  '2020/12/05'    117      148    4060.0
5  5         60  '2020/12/06'    102      127    3000.0
6  6         60  '2020/12/07'    110      136    3740.0
7  7        450  '2020/12/08'    104      134    2533.0
8  8         30  '2020/12/09'    109      133    1951.0
9  9         60  '2020/12/10'     98      124    2690.0

[19]: #Microatividade 4
      print(dados.tail(10))

      ID  Duration  Date      Pulse  Maxpulse  Calories
22 22         45      NaN     100      119    2820.0
23 23         60  '2020/12/23'    130      101    3000.0
24 24         45  '2020/12/24'    105      132    2460.0
25 25         60  '2020/12/25'    102      126    3345.0
26 26         60  '2020/12/26'    100      120    2500.0
27 27         60  '2020/12/27'     92      118    2410.0
28 28         60  '2020/12/28'    103      132      NaN
29 29         60  '2020/12/29'    100      132    2800.0
30 30         60  '2020/12/30'    102      129    3803.0
31 31         60  '2020/12/31'     92      115    2430.0
```

Microatividade 5: Descrever como exibir informações gerais sobre as colunas, linhas e dados de um conjunto de dados usando a biblioteca Pandas (Python)

Códigos desenvolvidos:

```
print(dados.info())
```

Saida do código:

```
#Microatividade 5
print(dados.info())

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 32 entries, 0 to 31
Data columns (total 6 columns):
 #   Column      Non-Null Count  Dtype  
---  --
 0   ID          32 non-null    int64  
 1   Duration    32 non-null    int64  
 2   Date        31 non-null    object  
 3   Pulse       32 non-null    int64  
 4   Maxpulse    32 non-null    int64  
 5   Calories    30 non-null    float64 
dtypes: float64(1), int64(4), object(1)
memory usage: 1.6+ KB
None
```

Trabalho Prático

Códigos desenvolvidos:

#Trabalho prático

```
import numpy as np

dados = pd.read_csv(
    "pico_web.csv",
    sep=";",
    engine="python",
    encoding="utf-8"
)

print("\n[1] Informações gerais:")
print(dados.info())

print("\n[2] Primeiras 5 linhas:")
print(dados.head())

print("\n[3] Últimas 5 linhas:")
print(dados.tail())

dados_tratados = dados.copy()

dados_tratados["Date"] =
dados_tratados["Date"].astype(str).str.replace("'",
regex=False)
```

```

dados_tratados["Calories"] = dados_tratados["Calories"].fillna(0)

print("\n[4] Após preencher Calories nulos com 0:")
print(dados_tratados)

dados_tratados["Date"] = dados_tratados["Date"].replace("nan",
"1900/01/01")

print("\n[5] Após substituir datas nulas por '1900/01/01':")
print(dados_tratados)

dados_tratados["Date"] = dados_tratados["Date"].replace("1900/01/01", np.nan)

dados_tratados["Date"] = dados_tratados["Date"].replace("20201226",
"2020/12/26")

print("\n[6] Após corrigir '20201226' para '2020/12/26':")
print(dados_tratados["Date"])

dados_tratados["Date"] = pd.to_datetime(
    dados_tratados["Date"],
    format="%Y/%m/%d",
    errors="coerce"
)

print("\n[7] Após converter coluna Date para datetime:")
print(dados_tratados)

```

```

dados_tratados = dados_tratados.dropna(subset=["Date"])

print("\n[8] DATAFRAME FINAL após remover linha com Date nulo:")

print(dados_tratados)

print(f"\nTotal de linhas no dataset final: {len(dados_tratados)}")

```

Saida do codigo:

```

[21]
✓ Os
print("\n[8] DATAFRAME FINAL após remover linha com Date nulo:")
print(dados_tratados)
print(f"\nTotal de linhas no dataset final: {len(dados_tratados)}")

[1] Informações gerais:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 32 entries, 0 to 31
Data columns (total 6 columns):
#   Column      Non-Null Count  Dtype
---  -
0   ID           32 non-null      int64
1   Duration     32 non-null      int64
2   Date         31 non-null      object
3   Pulse        32 non-null      int64
4   Maxpulse     32 non-null      int64
5   Calories     30 non-null      float64
dtypes: float64(1), int64(4), object(1)
memory usage: 1.6+ KB
None

[2] Primeiras 5 linhas:
   ID  Duration      Date  Pulse  Maxpulse  Calories
0   0         60  '2020/12/01'   110      130    4091.0
1   1         60  '2020/12/02'   117      145    4790.0
2   2         60  '2020/12/03'   103      135    3400.0
3   3         45  '2020/12/04'   109      175    2824.0
4   4         45  '2020/12/05'   117      148    4060.0

[3] Últimas 5 linhas:
   ID  Duration      Date  Pulse  Maxpulse  Calories
27  27         60  '2020/12/27'    92      118    2410.0
28  28         60  '2020/12/28'   103      132      NaN
29  29         60  '2020/12/29'   100      132    2800.0
30  30         60  '2020/12/30'   102      129    3803.0
31  31         60  '2020/12/31'    92      115    2430.0

[4] Após preencher Calories nulos com 0:
   ID  Duration      Date  Pulse  Maxpulse  Calories
0   0         60  2020/12/01   110      130    4091.0
1   1         60  2020/12/02   117      145    4790.0
2   2         60  2020/12/03   103      135    3400.0
3   3         45  2020/12/04   109      175    2824.0

```

Repositorio GIT

<https://github.com/KainDuPineu/Pico-Web>